

# ImageClassifier10

## Modelo con Arquitectura Simple - VERSION 10

```
[1]: import os
import tensorflow as tf
import keras
import numpy as np
import matplotlib.pyplot as plt
os.environ['KMP_DUPLICATE_LIB_OK']='True' #Configuración para compatibilidad de
↳matplotlib
```

### 1. Procesar imagenes

Partimos de un dataset con 9 categorias diferentes: ['Drought\_Disaster', 'Earthquake\_Disaster', 'LandSlide\_Disaster', 'Non\_Damage\_Buildings\_Street', 'Non\_Damage\_Sea', 'Non\_Damage\_Wildlife\_Forest', 'Urban\_Fire\_Disaster', 'Water\_Disaster', 'Wild\_Fire\_Disaster']

Cada carpeta cuenta con un nuemro diferente de imagenes, entre 200 y 4000 imagenes por clase.

Para obtenes un dataset balanceado, obtendremos un conjunto de imagenes representativas de cada grupo y realizaremos un aumento de imagenes con ellas para conseguir un número parecido de imagenes para cada clase.

```
[2]: data_dir='data' #Guarda la ruta donde se encuentra la bases de datos
class_names=os.listdir(data_dir) #Obtiene el nombre de las carpetas
print(class_names)
```

```
['Drought_Disaster', 'Earthquake_Disaster', 'LandSlide_Disaster',
'Non_Damage_Buildings_Street', 'Non_Damage_Sea', 'Non_Damage_Wildlife_Forest',
'Urban_Fire_Disaster', 'Water_Disaster', 'Wild_Fire_Disaster']
```

```
[3]: # Limpieza de imagenes corruptas, solo es necesario ejecutar una vez.
for image_class in os.listdir(data_dir): #lista de carpetas
    ↳en 'data'
        for image in os.listdir(os.path.join(data_dir, image_class)): #loop por todas las
    ↳imagenes
            image_path = os.path.join(data_dir, image_class, image)
            try:
                img = cv2.imread(image_path) # Comprobamos que se puede leer con
    ↳opencv/cv2
                tip = imghdr.what(image_path) # Comprobamos que las extensiones sean
    ↳['jpeg', 'jpg', 'bmp', 'png']
                if tip not in image_exts:
                    print('Image not in ext list {}'.format(image_path))
                    os.remove(image_path)
```

```

except Exception as e:
    print('Issue with image {}'.format(image_path))
    os.remove(image_path)

```

```

[4]: import random
from pathlib import Path
import shutil
from PIL import Image
from tensorflow.keras.preprocessing.image import ImageDataGenerator

# Creamos la base de datos balanceada

# Configuración inicial
original_data_dir = 'data'
balanced_data_dir = 'data_balanced'
target_size = (256, 256)          # Ajusta según necesidad
batch_size = 32
max_images_per_class = 600

# Crear el directorio balanceado limpio con la misma estructura
if os.path.exists(balanced_data_dir):
    shutil.rmtree(balanced_data_dir)
os.makedirs(balanced_data_dir)

# Crear un generador de datos para la aumentación
datagen = ImageDataGenerator(
    rotation_range=40,
    width_shift_range=0.2,
    height_shift_range=0.2,
    shear_range=0.2,
    zoom_range=0.2,
    horizontal_flip=True,
    fill_mode='nearest'
)

# Crear la lista de imágenes y etiquetas vacía.
class_names = (os.listdir(original_data_dir))
image_paths = []
labels = []

# Recolectar imágenes y aplicar aumentación si es necesario

# Para cada clase recorre el mismo loop, guarda las imágenes y aumenta datos si es necesario
for label_index, class_name in enumerate(class_names):
    orig_class_dir = os.path.join(original_data_dir, class_name)
    new_class_dir = os.path.join(balanced_data_dir, class_name)
    os.makedirs(new_class_dir, exist_ok=True)

    # Obtiene lista de los paths de las imágenes para cada categoría
    all_images = [

```

```

        os.path.join(orig_class_dir, fname)
    for fname in os.listdir(orig_class_dir)
    if fname.lower().endswith(('.png', '.jpg', '.jpeg'))
]

# Seleccionar hasta 'max_images_per_class' imágenes
selected_images = random.sample(all_images, min(len(all_images),
↪max_images_per_class))

# Copiar las imágenes seleccionadas al nuevo directorio
for image_path in selected_images:
    shutil.copy(image_path, os.path.join(balanced_data_dir, class_name))
print(f"Imágenes de la clase {class_name} copiadas a nuevo directorio")

# Si la clase tiene menos de max imágenes, aplicamos Data Augmentation
if len(selected_images) < max_images_per_class:
    print(f"Aplicando aumentación a la clase {class_name} para alcanzar
↪{max_images_per_class} imágenes...")

    # Usamos data augmentation para generar imágenes adicionales
    images_needed = max_images_per_class - len(selected_images)

    # Usamos data augmentation para generar imágenes adicionales
    i = 0
    for image_path in selected_images:
        if i >= images_needed:
            break
        img = Image.open(image_path).convert('RGB').resize(target_size)
        x = np.array(img)
        x = np.expand_dims(np.array(img), axis=0)

        # Generamos nuevas imágenes y las copiamos a la carpeta nueva
        for batch in datagen.flow(x, batch_size=1, save_to_dir=os.path.
↪join(balanced_data_dir, class_name), save_prefix='aug', save_format='png'):
            i += 1
            break # solo una imagen por iteración

    print(f"Aumentación a la clase {class_name} realizada")

# Actualizamos la lista de imágenes seleccionadas después de la aumentación
selected_images = [
    os.path.join(balanced_data_dir, class_name, fname)
    for fname in os.listdir(os.path.join(balanced_data_dir, class_name))
    if fname.lower().endswith(('.png', '.jpg', '.jpeg'))
]

# Actualizamos las rutas y etiquetas
image_paths.extend(selected_images)
labels.extend([label_index] * len(selected_images))

print("\nImágenes balanceadas y guardadas en 'data_balanced'")

```

Imágenes de la clase Drought\_Disaster copiadas a nuevo directorio  
 Aplicando aumentación a la clase Drought\_Disaster para alcanzar 600 imágenes...  
 Aumentación a la clase Drought\_Disaster realizada  
 Imágenes de la clase Earthquake\_Disaster copiadas a nuevo directorio  
 Aplicando aumentación a la clase Earthquake\_Disaster para alcanzar 600 imágenes...  
 Aumentación a la clase Earthquake\_Disaster realizada  
 Imágenes de la clase Landslide\_Disaster copiadas a nuevo directorio  
 Aplicando aumentación a la clase Landslide\_Disaster para alcanzar 600 imágenes...  
 Aumentación a la clase Landslide\_Disaster realizada  
 Imágenes de la clase Non\_Damage\_Buildings\_Street copiadas a nuevo directorio  
 Imágenes de la clase Non\_Damage\_Sea copiadas a nuevo directorio  
 Imágenes de la clase Non\_Damage\_Wildlife\_Forest copiadas a nuevo directorio  
 Imágenes de la clase Urban\_Fire\_Disaster copiadas a nuevo directorio  
 Aplicando aumentación a la clase Urban\_Fire\_Disaster para alcanzar 600 imágenes...  
 Aumentación a la clase Urban\_Fire\_Disaster realizada  
 Imágenes de la clase Water\_Disaster copiadas a nuevo directorio  
 Imágenes de la clase Wild\_Fire\_Disaster copiadas a nuevo directorio  
 Aplicando aumentación a la clase Wild\_Fire\_Disaster para alcanzar 600 imágenes...  
 Aumentación a la clase Wild\_Fire\_Disaster realizada  
  
 Imágenes balanceadas y guardadas en 'data\_balanced'

## 2. Normalizamos datos

```

[5]: # Escalar imágenes para píxeles de valores entre 0 y 1, en vez de entre 0 y 255
      # Convertir a arrays normalizados
      image_arrays = []
      for path in image_paths:
          img = Image.open(path).convert('RGB').resize(target_size)
          img_array = np.array(img).astype(np.float32) / 255.0 # Normalizar
          image_arrays.append(img_array)

      X = np.array(image_arrays)
      y = np.array(labels)

      print(f"\nConjunto escalado: X.shape = {X.shape}, y.shape = {y.shape}")
  
```

Conjunto escalado: X.shape = (5191, 256, 256, 3), y.shape = (5191,)

```

[6]: # Comprobamos que el formato es correcto
      X[1] # Los píxeles se encuentran entre 0 y 1
  
```

```

[8]: array([[0.69803923, 0.78039217, 0.84705883],
           [0.69411767, 0.78039217, 0.84705883],
           [0.6901961 , 0.78039217, 0.84313726],
           ...,
           [0.91764706, 0.92156863, 0.9372549 ],
           [0.90588236, 0.9098039 , 0.9254902 ],
           [0.8980392 , 0.9019608 , 0.91764706]])
  
```

```

[[0.69803923, 0.78039217, 0.84705883],
 [0.69411767, 0.7764706 , 0.84313726],
 [0.6901961 , 0.77254903, 0.8352941 ],
 ...,
 [0.94509804, 0.9490196 , 0.9607843 ],
 [0.94509804, 0.9490196 , 0.9607843 ],
 [0.9372549 , 0.9411765 , 0.9529412 ]],

[[0.7058824 , 0.79607844, 0.85882354],
 [0.7019608 , 0.7882353 , 0.8509804 ],
 [0.7058824 , 0.78431374, 0.8509804 ],
 ...,
 [0.9529412 , 0.95686275, 0.9647059 ],
 [0.95686275, 0.9607843 , 0.96862745],
 [0.9529412 , 0.95686275, 0.9647059 ]],

...,

[[0.3254902 , 0.32941177, 0.14901961],
 [0.32941177, 0.3529412 , 0.1764706 ],
 [0.3529412 , 0.38039216, 0.18431373],
 ...,
 [0.59607846, 0.3882353 , 0.3019608 ],
 [0.6666667 , 0.44313726, 0.34901962],
 [0.68235296, 0.44313726, 0.3254902 ]],

[[0.4745098 , 0.49019608, 0.25490198],
 [0.3882353 , 0.43137255, 0.20392157],
 [0.3137255 , 0.34117648, 0.16470589],
 ...,
 [0.5882353 , 0.38039216, 0.2784314 ],
 [0.60784316, 0.3882353 , 0.26666668],
 [0.6666667 , 0.4392157 , 0.30980393]],

[[0.35686275, 0.40392157, 0.17254902],
 [0.30588236, 0.3647059 , 0.16470589],
 [0.31764707, 0.3529412 , 0.18431373],
 ...,
 [0.6745098 , 0.44313726, 0.32156864],
 [0.7529412 , 0.50980395, 0.36862746],
 [0.79607844, 0.54901963, 0.40784314]]], dtype=float32)

```

```

[7]: # Comprobamos que el formato es correcto
     y #las etiquetas se representan con números enteros

```

```

[9]: array([0, 0, 0, ..., 8, 8, 8])

```

### 3. Dividimos datos

```
[8]: from sklearn.model_selection import train_test_split

# División estratificada (train, val, test)
X_train_val, X_test, y_train_val, y_test = train_test_split(
    X, y, test_size=0.10, stratify=y, random_state=42)

X_train, X_val, y_train, y_val = train_test_split(
    X_train_val, y_train_val, test_size=0.125, stratify=y_train_val, random_state=42)

# 0.125 0.10 / 0.80 → para que val sea el 20% final
```

Para facilitar el trabajo a lo largo del entrenamiento guardamos el conjunto de datos para poder acceder a el de forma rápida y sencilla, cada vez que deseemos entrenar.

```
[9]: # Guardamos el conjunto de datos dividido , para su fácil acceso
# Crea la carpeta si no existe
os.makedirs("split_data", exist_ok=True)

# Guardar todos los arrays en un solo archivo comprimido
np.savez_compressed('split_data/dataset.npz',
                    X_train=X_train,
                    y_train=y_train,
                    X_val=X_val,
                    y_val=y_val,
                    X_test=X_test,
                    y_test=y_test)

print("Datos guardados en 'split_data/dataset.npz'")
```

Datos guardados en 'split\_data/dataset.npz'

### 4. Cargamos y visualizamos datos

```
[10]: #Cargamos datos desde split_data
import numpy as np

# Cargar el archivo comprimido
data = np.load('split_data/dataset.npz')

# Asignar a variables
X_train = data['X_train']
y_train = data['y_train']
X_val = data['X_val']
y_val = data['y_val']
X_test = data['X_test']
y_test = data['y_test']

print("Datos cargados correctamente desde 'split_data/dataset.npz'")
```

Datos cargados correctamente desde 'split\_data/dataset.npz'

```
[11]: print(f"Train: {len(X_train)}, Val: {len(X_val)}, Test: {len(X_test)}")
class_names=os.listdir('data') #Obtiene el nombre de las carpetas
```

```
# Mostrar el número de imágenes por clase en el conjunto final
print("\nDistribución de imágenes por clase:")
for i, class_name in enumerate(class_names):
    train_count = sum([1 for label in y_train if label == i])
    val_count = sum([1 for label in y_val if label == i])
    test_count = sum([1 for label in y_test if label == i])
    print(f"{class_name}: Entrenamiento={train_count}, Validación={val_count},
    ↪Test={test_count}")
```

Train: 4087, Val: 584, Test: 519

Distribución de imágenes por clase:

```
Drought_Disaster: Entrenamiento=310, Validación=44, Test=39
Earthquake_Disaster: Entrenamiento=473, Validación=67, Test=60
LandSlide_Disaster: Entrenamiento=472, Validación=67, Test=60
Non_Damage_Buildings_Street: Entrenamiento=473, Validación=67, Test=60
Non_Damage_Sea: Entrenamiento=472, Validación=68, Test=60
Non_Damage_Wildlife_Forest: Entrenamiento=472, Validación=68, Test=60
Urban_Fire_Disaster: Entrenamiento=471, Validación=67, Test=60
Water_Disaster: Entrenamiento=472, Validación=68, Test=60
Wild_Fire_Disaster: Entrenamiento=472, Validación=68, Test=60
```

```
[12]: import matplotlib.pyplot as plt
import numpy as np
from PIL import Image

img_size = (256,256)
data_dir='data'
class_names=os.listdir(data_dir) #Obtiene el nombre de las carpetas

# Crear la figura 3x3
fig, ax = plt.subplots(nrows=2, ncols=5, figsize=(20, 7))

# Obtener una imagen de cada clase y mostrarla
for idx, class_name in enumerate(class_names):

    # Obtener la ruta de las imágenes de la clase
    class_dir = os.path.join(data_dir, class_name)
    image_path = os.path.join(class_dir, os.listdir(class_dir)[1]) # Tomamos una
    ↪imagen
    img = Image.open(image_path).convert('RGB').resize(img_size)
    img_array = np.array(img) / 255.0 # Normalizamos a
    ↪0-1

    # Determinar la posición de la subgráfica
    row = idx // 5 # Calculamos la fila
    col = idx % 5 # Calculamos la columna

    # Mostrar la imagen
    ax[row, col].imshow(img_array)
    ax[row, col].title.set_text(class_name) # Establecer el título con el nombre de
    ↪la clase
    ax[row, col].title.set_fontsize(16) # Ajusta el tamaño de la fuente aquí
```

```

ax[row, col].axis('off') # Desactivar los ejes para una mejor
→ presentación

plt.tight_layout() # Ajusta el espaciado entre las subgráficas
plt.show()
plt.close()

```



## 5. Arquitectura del modelo

```

[13]: from tensorflow.keras.models import Sequential
      from tensorflow.keras.layers import Conv2D, MaxPooling2D, GlobalAveragePooling2D, Dense
      from tensorflow.keras.layers import Dropout, BatchNormalization
      from tensorflow.keras.callbacks import EarlyStopping, ReduceLROnPlateau, TensorBoard

```

```

[14]: #Creamos nuestro modelo:
      model = Sequential()

```

```

[15]: # Añadimos capas
      #Capa convolucional: 32 filtros de 3x3 pixels, stride = 1, activation = relu +
      →entradas: 1 image
      model.add(Conv2D(32, (3,3), 1, activation='relu', input_shape=(256,256,3)))
      model.add(MaxPooling2D())

      #Capa convolucional: 64 filtros de 3x3 pixels, stride = 1, activation = relu
      model.add(Conv2D(64, (3,3), 1, activation='relu'))
      model.add(MaxPooling2D())

      #Capa convolucional: 128 filtros de 3x3 pixels, stride = 1, activation = relu
      model.add(Conv2D(128, (3,3), 1, activation='relu'))
      model.add(MaxPooling2D())

      #Capa de normalización de los resultados
      model.add(BatchNormalization())

      #Conectar capas convolucionales con capas densas
      model.add(GlobalAveragePooling2D())

```



```

    #Añadimos capa densa de 256 neuron con ReLU
model.add(Dense(256, activation='relu'))

    #Usamos Dropout para evitar over-fitting
model.add(Dropout(0.5))

    #Capa de salida con tantas neuronas como clases con 'softmax'
model.add(Dense(9, activation='softmax')) #Capa de salida

```

```

[16]: # Añadimos optimizador
model.compile(optimizer='adam',
              loss=tf.losses.SparseCategoricalCrossentropy(),
              metrics=['accuracy']
            )

```

```

[17]: # Callbacks

    # Early Stopping Call-Backc para parar el proceso de entrenamiento después de
    ↳ 'patience' épocas si no mejora
early_stop = EarlyStopping(patience=5, restore_best_weights=True, monitor='val_loss')

    # ReduceLROnPlateau Call-Back para reducir la tasa de aprendizaje según el parámetro
    ↳ 'monitor'
reduce_lr = ReduceLROnPlateau(patience=3, factor=0.2, monitor='val_loss', min_lr=1e-5)

    # Usamos Tensorboard, para guardar los datos de entrenamiento
tensorboard_callback = TensorBoard('logs')

```

```

[18]: # Visualizamos las entradas y salida de cada capa
for layer in model.layers:
    print(f"Layer name: {layer.name}")
    print(f"    Input shape: {layer.input_shape}")
    print(f"    Output shape: {layer.output_shape}")
    print("-" * 10)

```

```

Layer name: conv2d
    Input shape: (None, 256, 256, 3)
    Output shape: (None, 254, 254, 32)
-----
Layer name: max_pooling2d
    Input shape: (None, 254, 254, 32)
    Output shape: (None, 127, 127, 32)
-----
Layer name: conv2d_1
    Input shape: (None, 127, 127, 32)
    Output shape: (None, 125, 125, 64)
-----
Layer name: max_pooling2d_1
    Input shape: (None, 125, 125, 64)
    Output shape: (None, 62, 62, 64)
-----
Layer name: conv2d_2
    Input shape: (None, 62, 62, 64)
    Output shape: (None, 60, 60, 128)

```

```

-----
Layer name: max_pooling2d_2
  Input shape: (None, 60, 60, 128)
  Output shape: (None, 30, 30, 128)
-----
Layer name: batch_normalization
  Input shape: (None, 30, 30, 128)
  Output shape: (None, 30, 30, 128)
-----
Layer name: global_average_pooling2d
  Input shape: (None, 30, 30, 128)
  Output shape: (None, 128)
-----
Layer name: dense
  Input shape: (None, 128)
  Output shape: (None, 256)
-----
Layer name: dropout
  Input shape: (None, 256)
  Output shape: (None, 256)
-----
Layer name: dense_1
  Input shape: (None, 256)
  Output shape: (None, 9)
-----

```

```
[19]: model.summary()
```

```
Model: "sequential_1"
```

Layer (type)	Output Shape	Param #
conv2d (Conv2D)	(None, 254, 254, 32)	896
max_pooling2d (MaxPooling2D)	(None, 127, 127, 32)	0
conv2d_1 (Conv2D)	(None, 125, 125, 64)	18496
max_pooling2d_1 (MaxPooling2D)	(None, 62, 62, 64)	0
conv2d_2 (Conv2D)	(None, 60, 60, 128)	73856
max_pooling2d_2 (MaxPooling2D)	(None, 30, 30, 128)	0
batch_normalization (Batch Normalization)	(None, 30, 30, 128)	512
global_average_pooling2d (GlobalAveragePooling2D)	(None, 128)	0
dense (Dense)	(None, 256)	33024

dropout (Dropout)	(None, 256)	0
dense_1 (Dense)	(None, 9)	2313

```
=====
Total params: 129,097
Trainable params: 128,841
Non-trainable params: 256
-----
```

## 6. Entrenamiento

```
[20]: hist = model.fit(
        X_train, y_train,
        batch_size=32,
        epochs=40,
        validation_data=(X_val, y_val),
        callbacks=[reduce_lr, early_stop, tensorboard_callback])
```

```
Epoch 1/40
128/128 [=====] - 81s 618ms/step - loss: 1.6092 -
accuracy: 0.4010 - val_loss: 2.0223 - val_accuracy: 0.1524 - lr: 0.0010
Epoch 2/40
128/128 [=====] - 77s 601ms/step - loss: 1.2496 -
accuracy: 0.5332 - val_loss: 1.6400 - val_accuracy: 0.4298 - lr: 0.0010
Epoch 3/40
128/128 [=====] - 76s 591ms/step - loss: 1.0995 -
accuracy: 0.5853 - val_loss: 1.4051 - val_accuracy: 0.4760 - lr: 0.0010
Epoch 4/40
128/128 [=====] - 77s 602ms/step - loss: 1.0207 -
accuracy: 0.6188 - val_loss: 1.3875 - val_accuracy: 0.5017 - lr: 0.0010
Epoch 5/40
128/128 [=====] - 76s 591ms/step - loss: 0.9211 -
accuracy: 0.6491 - val_loss: 1.3745 - val_accuracy: 0.4812 - lr: 0.0010
Epoch 6/40
128/128 [=====] - 76s 595ms/step - loss: 0.8769 -
accuracy: 0.6753 - val_loss: 1.4238 - val_accuracy: 0.5205 - lr: 0.0010
Epoch 7/40
128/128 [=====] - 75s 589ms/step - loss: 0.8478 -
accuracy: 0.6849 - val_loss: 3.4124 - val_accuracy: 0.3733 - lr: 0.0010
Epoch 8/40
128/128 [=====] - 77s 603ms/step - loss: 0.7953 -
accuracy: 0.7081 - val_loss: 0.8636 - val_accuracy: 0.6644 - lr: 0.0010
Epoch 9/40
128/128 [=====] - 76s 596ms/step - loss: 0.7725 -
accuracy: 0.7137 - val_loss: 1.6571 - val_accuracy: 0.5051 - lr: 0.0010
Epoch 10/40
128/128 [=====] - 76s 594ms/step - loss: 0.7377 -
accuracy: 0.7252 - val_loss: 0.9340 - val_accuracy: 0.6747 - lr: 0.0010
Epoch 11/40
128/128 [=====] - 76s 591ms/step - loss: 0.7205 -
accuracy: 0.7382 - val_loss: 0.8078 - val_accuracy: 0.7158 - lr: 0.0010
Epoch 12/40
```

128/128 [=====] - 76s 593ms/step - loss: 0.7145 -  
accuracy: 0.7362 - val\_loss: 2.0728 - val\_accuracy: 0.4401 - lr: 0.0010  
Epoch 13/40  
128/128 [=====] - 76s 593ms/step - loss: 0.6819 -  
accuracy: 0.7448 - val\_loss: 0.6700 - val\_accuracy: 0.7500 - lr: 0.0010  
Epoch 14/40  
128/128 [=====] - 76s 597ms/step - loss: 0.6588 -  
accuracy: 0.7524 - val\_loss: 2.0910 - val\_accuracy: 0.4589 - lr: 0.0010  
Epoch 15/40  
128/128 [=====] - 76s 591ms/step - loss: 0.6597 -  
accuracy: 0.7595 - val\_loss: 1.3543 - val\_accuracy: 0.5531 - lr: 0.0010  
Epoch 16/40  
128/128 [=====] - 77s 602ms/step - loss: 0.6120 -  
accuracy: 0.7734 - val\_loss: 0.6729 - val\_accuracy: 0.7483 - lr: 0.0010  
Epoch 17/40  
128/128 [=====] - 76s 593ms/step - loss: 0.5583 -  
accuracy: 0.7996 - val\_loss: 0.5505 - val\_accuracy: 0.7997 - lr: 2.0000e-04  
Epoch 18/40  
128/128 [=====] - 76s 595ms/step - loss: 0.5354 -  
accuracy: 0.8106 - val\_loss: 0.5416 - val\_accuracy: 0.7997 - lr: 2.0000e-04  
Epoch 19/40  
128/128 [=====] - 76s 591ms/step - loss: 0.5186 -  
accuracy: 0.8136 - val\_loss: 0.5974 - val\_accuracy: 0.7860 - lr: 2.0000e-04  
Epoch 20/40  
128/128 [=====] - 76s 594ms/step - loss: 0.5072 -  
accuracy: 0.8162 - val\_loss: 0.5688 - val\_accuracy: 0.7860 - lr: 2.0000e-04  
Epoch 21/40  
128/128 [=====] - 76s 590ms/step - loss: 0.5066 -  
accuracy: 0.8118 - val\_loss: 0.5308 - val\_accuracy: 0.8048 - lr: 2.0000e-04  
Epoch 22/40  
128/128 [=====] - 75s 586ms/step - loss: 0.5036 -  
accuracy: 0.8211 - val\_loss: 0.5063 - val\_accuracy: 0.8322 - lr: 2.0000e-04  
Epoch 23/40  
128/128 [=====] - 77s 599ms/step - loss: 0.4950 -  
accuracy: 0.8216 - val\_loss: 0.6000 - val\_accuracy: 0.7928 - lr: 2.0000e-04  
Epoch 24/40  
128/128 [=====] - 75s 589ms/step - loss: 0.4878 -  
accuracy: 0.8229 - val\_loss: 0.5203 - val\_accuracy: 0.8134 - lr: 2.0000e-04  
Epoch 25/40  
128/128 [=====] - 76s 592ms/step - loss: 0.4838 -  
accuracy: 0.8231 - val\_loss: 0.4843 - val\_accuracy: 0.8253 - lr: 2.0000e-04  
Epoch 26/40  
128/128 [=====] - 75s 587ms/step - loss: 0.4700 -  
accuracy: 0.8326 - val\_loss: 0.4854 - val\_accuracy: 0.8134 - lr: 2.0000e-04  
Epoch 27/40  
128/128 [=====] - 76s 595ms/step - loss: 0.4685 -  
accuracy: 0.8270 - val\_loss: 0.5263 - val\_accuracy: 0.8082 - lr: 2.0000e-04  
Epoch 28/40  
128/128 [=====] - 75s 588ms/step - loss: 0.4642 -  
accuracy: 0.8312 - val\_loss: 0.4865 - val\_accuracy: 0.8305 - lr: 2.0000e-04  
Epoch 29/40  
128/128 [=====] - 76s 596ms/step - loss: 0.4427 -  
accuracy: 0.8412 - val\_loss: 0.4579 - val\_accuracy: 0.8408 - lr: 4.0000e-05  
Epoch 30/40

```

128/128 [=====] - 75s 588ms/step - loss: 0.4220 -
accuracy: 0.8439 - val_loss: 0.4742 - val_accuracy: 0.8390 - lr: 4.0000e-05
Epoch 31/40
128/128 [=====] - 76s 593ms/step - loss: 0.4315 -
accuracy: 0.8417 - val_loss: 0.4684 - val_accuracy: 0.8373 - lr: 4.0000e-05
Epoch 32/40
128/128 [=====] - 75s 589ms/step - loss: 0.4246 -
accuracy: 0.8532 - val_loss: 0.4751 - val_accuracy: 0.8339 - lr: 4.0000e-05
Epoch 33/40
128/128 [=====] - 76s 595ms/step - loss: 0.4262 -
accuracy: 0.8490 - val_loss: 0.4602 - val_accuracy: 0.8373 - lr: 1.0000e-05
Epoch 34/40
128/128 [=====] - 75s 587ms/step - loss: 0.4388 -
accuracy: 0.8419 - val_loss: 0.4553 - val_accuracy: 0.8476 - lr: 1.0000e-05
Epoch 35/40
128/128 [=====] - 76s 596ms/step - loss: 0.4235 -
accuracy: 0.8456 - val_loss: 0.4566 - val_accuracy: 0.8442 - lr: 1.0000e-05
Epoch 36/40
128/128 [=====] - 77s 600ms/step - loss: 0.4223 -
accuracy: 0.8414 - val_loss: 0.4580 - val_accuracy: 0.8425 - lr: 1.0000e-05
Epoch 37/40
128/128 [=====] - 75s 588ms/step - loss: 0.4191 -
accuracy: 0.8485 - val_loss: 0.4536 - val_accuracy: 0.8476 - lr: 1.0000e-05
Epoch 38/40
128/128 [=====] - 75s 585ms/step - loss: 0.4236 -
accuracy: 0.8476 - val_loss: 0.4521 - val_accuracy: 0.8442 - lr: 1.0000e-05
Epoch 39/40
128/128 [=====] - 76s 597ms/step - loss: 0.4243 -
accuracy: 0.8459 - val_loss: 0.4611 - val_accuracy: 0.8442 - lr: 1.0000e-05
Epoch 40/40
128/128 [=====] - 76s 593ms/step - loss: 0.4239 -
accuracy: 0.8473 - val_loss: 0.4541 - val_accuracy: 0.8476 - lr: 1.0000e-05

```

## 7. Evaluar resultados

```

[21]: # Resultados finales del entrenamiento
train_loss, train_acc = model.evaluate(X_train, y_train, verbose=0)
print(f"Train Loss: {train_loss:.4f}, Train Accuracy: {train_acc:.4f}")

```

Train Loss: 0.3986, Train Accuracy: 0.8503

```

[22]: # Visualizar el proceso de entrenamiento
import matplotlib.pyplot as plt


fig = plt.figure(figsize = (15,5))
fig.suptitle('Results', fontsize=20)

plt.subplot(121)
plt.plot(hist.history['loss'], color='teal', label='loss')
plt.plot(hist.history['val_loss'], color='orange', label='val_loss')
plt.title('Loss function', fontsize=15)
plt.ylabel('loss', fontsize=15)
plt.xlabel('epochs', fontsize=15)
plt.legend(loc="upper left")

```

```
plt.subplot(122)
plt.plot(hist.history['accuracy'], color='teal', label='accuracy')
plt.plot(hist.history['val_accuracy'], color='orange', label='val_accuracy')
plt.title('Accuracy', fontsize=15)
plt.ylabel('accuracy', fontsize=15)
plt.xlabel('epochs', fontsize=15)
plt.legend(loc="upper left")

plt.show()
plt.close()
```



```
[23]: # Calcular las predicciones sobre el conjunto de validación
y_true = []
y_pred = []

for i in range(len(X_val)):
    image_batch = np.expand_dims(X_val[i], axis=0) # Asegura que la imagen esté en el
    # formato (1, altura, ancho, canales)
    label_batch = np.expand_dims(y_val[i], axis=0) # Asegura que la etiqueta esté en
    # el formato correcto

    preds = model.predict(image_batch) # Realiza la predicción
    y_true.append(label_batch[0]) # Agregar la etiqueta verdadera
    y_pred.append(np.argmax(preds, axis=1)[0]) # Agregar la clase predicha
```

```
1/1 [=====] - 0s 105ms/step
1/1 [=====] - 0s 22ms/step
1/1 [=====] - 0s 22ms/step

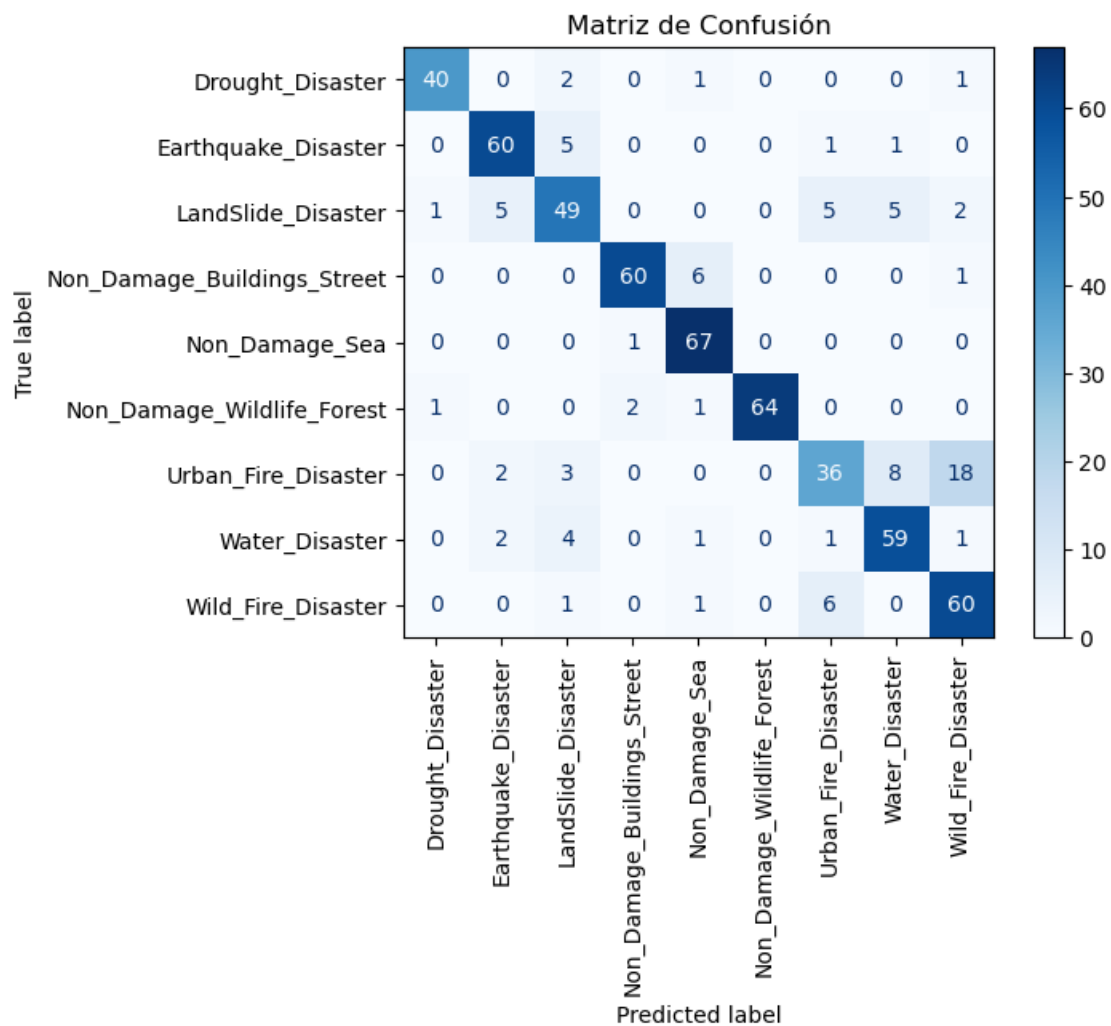
...

1/1 [=====] - 0s 20ms/step
1/1 [=====] - 0s 19ms/step
1/1 [=====] - 0s 19ms/step
```

```
[24]: from sklearn.metrics import confusion_matrix, ConfusionMatrixDisplay
import matplotlib.pyplot as plt

# Elaborar las matrices de confusión
cm = confusion_matrix(y_true, y_pred)
class_names=os.listdir('data_balanced')

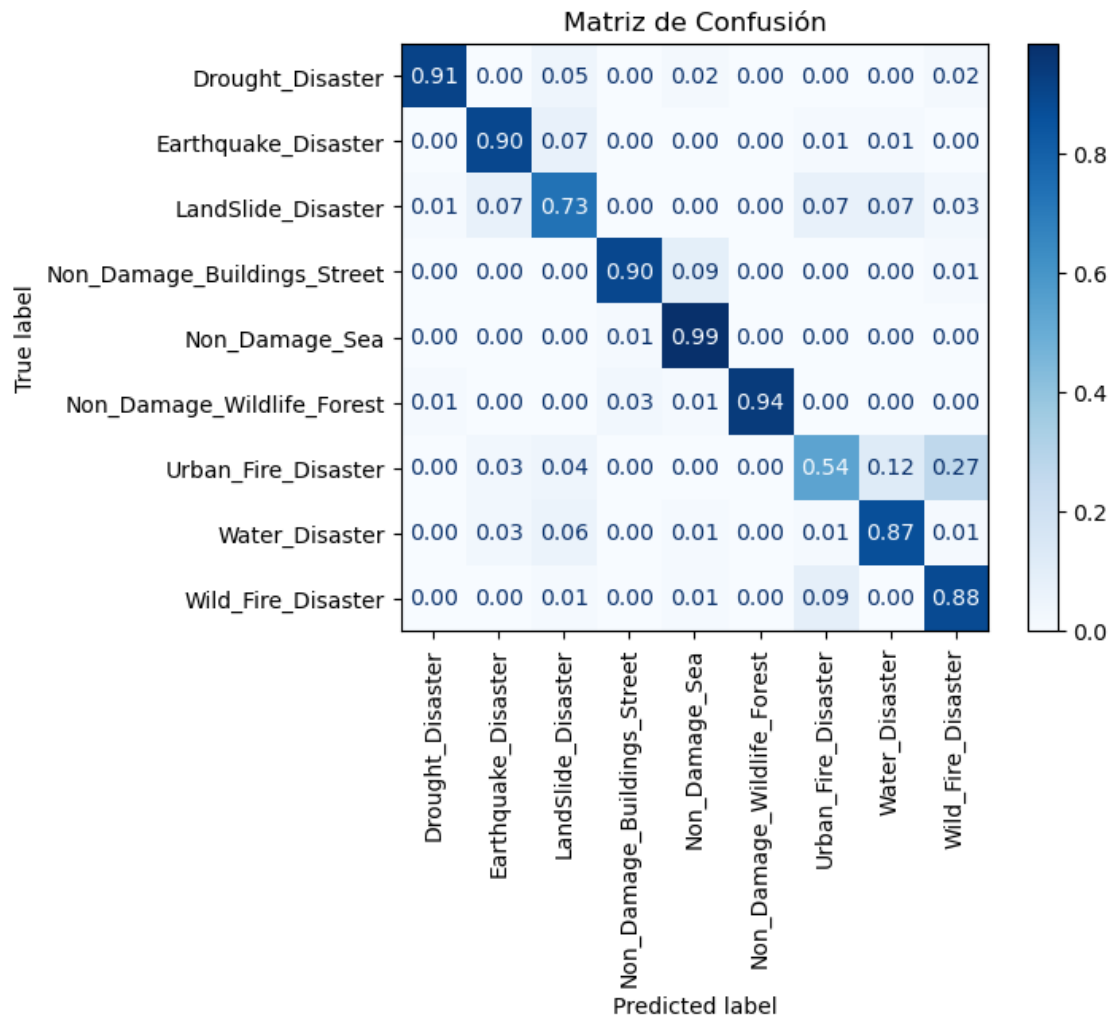
# Mostrar con etiquetas de clase
disp = ConfusionMatrixDisplay(confusion_matrix=cm, display_labels=class_names)
disp.plot(xticks_rotation='vertical', cmap='Blues')
plt.title('Matriz de Confusión')
plt.show()
plt.close()
```



```
[25]: from sklearn.metrics import confusion_matrix, ConfusionMatrixDisplay
import numpy as np
```

```
# Calcular la matriz de confusión normalizada (por filas)
cm = confusion_matrix(y_true, y_pred, normalize='true') # 0 'pred' o 'all' según lo
→ que desees
class_names=os.listdir('data_balanced')

# Mostrarla
disp = ConfusionMatrixDisplay(confusion_matrix=cm, display_labels=class_names)
disp.plot(xticks_rotation='vertical', cmap='Blues', values_format='.2f') # Mostrar
→ valores con decimales
plt.title('Matriz de Confusión')
plt.show()
plt.close()
```



## 8. Test

Se procede a analizar con profundidad el rendimiento en el grupo de prueba (imagenes que el modelo no ha visto)



```
[26]: import numpy as np
from sklearn.metrics import classification_report

# Se obtiene las predicciones y las etiquetas correctas

# Obtener todas las predicciones de una vez
y_pred_probs = model.predict(X_test)
y_pred = np.argmax(y_pred_probs, axis=1)

# Asegurar que etiquetas son arrays planos
y_true_flat = y_test.ravel()
y_pred_flat = y_pred.ravel()

class_names=os.listdir('data_balanced')

print("\nClassification Report:")
print(classification_report(y_true_flat, y_pred_flat, target_names=class_names))
```

17/17 [=====] - 2s 129ms/step

Classification Report:

	precision	recall	f1-score	support
Drought_Disaster	0.92	0.85	0.88	39
Earthquake_Disaster	0.81	0.87	0.84	60
LandSlide_Disaster	0.73	0.73	0.73	60
Non_Damage_Buildings_Street	1.00	0.90	0.95	60
Non_Damage_Sea	0.95	1.00	0.98	60
Non_Damage_Wildlife_Forest	0.95	1.00	0.98	60
Urban_Fire_Disaster	0.76	0.65	0.70	60
Water_Disaster	0.84	0.82	0.83	60
Wild_Fire_Disaster	0.71	0.83	0.77	60
accuracy			0.85	519
macro avg	0.85	0.85	0.85	519
weighted avg	0.85	0.85	0.85	519

## 9. Guardar el modelo

Se guarda el modelo final con la función `load.model` en el directorio.

```
[27]: model.save(os.path.join('models', 'imageclassifier10.h5'))
```

## 10. Cargar el modelo

```
[28]: from tensorflow.keras.models import load_model
```

```
[29]: model = load_model(os.path.join('models', 'imageclassifier10.h5'))
```

```
[ ]:
```